

6. Random matrices and covariance estimation

担当：みーとみ

2021 年 6 月 30 日, 7 月 7 日

Table of Contents

6.1 Some preliminaries

6.2 Wishart matrices and their behavior

6.3 Covariance matrices from sub-Gaussian ensembles

6.1 Some preliminaries

- Notation とこの章で使う preliminary results の説明から.

6.1.1 Notation and basic facts

- 行列 $A \in \mathbb{R}^{n \times m}$ with $n \geq m$ に対し、(順序付き) 特異値を

$$\sigma_{\max}(A) = \sigma_1(A) \geq \sigma_2(A) \geq \cdots \geq \sigma_m(A) = \sigma_{\min}(A) \geq 0$$

と書く.

- 最小・最大特異値は次のように characterize される:

$$\sigma_{\max}(A) = \max_{v \in \mathbb{S}^{m-1}} \|Av\|_2 \quad \text{and} \quad \sigma_{\min}(A) = \min_{v \in \mathbb{S}^{m-1}} \|Av\|_2, \quad (6.1)$$

ただし $\mathbb{S}^{d-1} := \{v \in \mathbb{R}^d \mid \|v\|_2 = 1\}$ は \mathbb{R}^d 上の Euclidean unit sphere.

- また次の同値性が成り立つ: $\|A\|_2 = \sigma_{\max}(A)$.

- ・ 対称行列の集合を $\mathcal{S}^{d \times d} := \{Q \in \mathbb{R}^{d \times d} \mid Q = Q^T\}$ とし, その半正定値行列からなる部分集合を

$$\mathcal{S}_+^{d \times d} := \left\{ Q \in \mathcal{S}^{d \times d} \mid Q \succeq 0 \right\} \quad (6.2)$$

と書く.

- ・ 任意の対称行列 $Q \in \mathcal{S}^{d \times d}$ は対角化可能であり, その固有値を

$$\gamma_{\max}(Q) = \gamma_1(Q) \geq \gamma_2 \geq \cdots \geq \gamma_d(Q) = \gamma_{\min}(Q)$$

とする.

- ・ このとき, $Q \succeq 0 \Leftrightarrow \gamma_{\min}(Q) \geq 0$.

- ・ 最小・最大固有値の “Rayleigh – Ritz variational characterization”:

$$\gamma_{\max}(Q) = \max_{v \in \mathbb{S}^{d-1}} v^T Q v \quad \text{and} \quad \gamma_{\min}(Q) = \min_{v \in \mathbb{S}^{d-1}} v^T Q v. \quad (6.3)$$

- ・ 任意の対称行列 Q に対し, その ℓ_2 -operator norm は,

$$\|Q\|_2 = \max \{ \gamma_{\max}(Q), |\gamma_{\min}(Q)| \} = \max_{v \in \mathbb{S}^{d-1}} |v^T Q v|. \quad (6.4)$$

- ・ 最後に, 行列 $A \in \mathbb{R}^{n \times m}$ with $n \geq m$ に対し, m -次元対称行列 $R := A^T A$ を考えると,

$$\gamma_j(R) = (\sigma_j(A))^2 \quad \text{for } j = 1, \dots, m.$$

6.1.2 Set-up of covariance estimation

- $\{x_1, \dots, x_m\}$ は, \mathbb{R}^d 上の zero-mean \cdot covariance $\Sigma = \text{cov}(x_1) \in \mathbb{S}_+^{d \times d}$ なる分布からの n 個の i.i.d. サンプルとする.
- Σ の standard estimator は, 次の *sample covariance matrix* である:

$$\hat{\Sigma} := \frac{1}{n} \sum_{i=1}^n x_i x_i^T. \quad (6.5)$$

- 各 x_i は zero-mean なので $\mathbb{E}[x_i x_i^T] = \Sigma$ であり, $\hat{\Sigma}$ は Σ の unbiased estimator.
- したがって $\hat{\Sigma} - \Sigma$ は期待値ゼロとなり, その ℓ_2 -operator norm によって測った error の bound を求めることがこの章の goal となる.

- ・ (6.4) の ℓ_2 -operator norm の表現より, $|||\hat{\Sigma} - \Sigma|||_2 \leq \epsilon$ は以下と同値:

$$\max_{v \in \mathbb{S}^{d-1}} \left| \frac{1}{n} \sum_{i=1}^n \langle x_i, v \rangle^2 - v^T \Sigma v \right| \leq \epsilon. \quad (6.6)$$

- ・ つまり, $|||\hat{\Sigma} - \Sigma|||_2$ をコントロールすることは, v で indexed された関数クラス $x \mapsto \langle x, v \rangle^2$ の uniform law of large numbers を示すことと同値になる.

- ・ その ℓ_2 -operator norm をコントロールすることは, $\hat{\Sigma}$ の固有値の一様収束も意味する: Weyl's theorem の corollary より,

$$\max_{j=1,\dots,d} \left| \gamma_j(\hat{\Sigma}) - \gamma_j(\Sigma) \right| \leq |||\hat{\Sigma} - \Sigma|||_2. \quad (6.7)$$

- ・ また最後に, ランダム行列 $X \in \mathbb{R}^{n \times d}$ が, 第 i 行に x_i^T を持つものとする

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^{n \times d}$$

と,

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n x_i x_i^T = \frac{1}{n} X^T X$$

なので, $\hat{\Sigma}$ の固有値は X/\sqrt{n} の特異値の 2 乗となる.

6.2 Wishart matrices and their behavior

- ・ サンプル x_i は, d -次元正規分布 $\mathcal{N}(0, \Sigma)$ から i.i.d. で引かれるとする.
- ・ このとき,

$$X = \begin{pmatrix} x_1^T \\ \vdots \\ x_n^T \end{pmatrix} \in \mathbb{R}^{n \times d}$$

は, Σ -Gaussian ensemble から引かれると言う.

- ・ Sample covariance $\hat{\Sigma} = \frac{1}{n} X^T X$ は, a multivariate Wishart distribution に従う.

Theorem 6.1

$X \in \mathbb{R}^{n \times d}$ は Σ -Gaussian ensemble から引かれるとする. このとき, 任意の $\delta > 0$ に対し, 最大特異値 $\sigma_{\max}(X)$ は以下の upper deviation inequality を満たす:

$$\mathbb{P} \left[\frac{\sigma_{\max}(X)}{\sqrt{n}} \geq \gamma_{\max} \left(\sqrt{\Sigma} \right) (1 + \delta) + \sqrt{\frac{\text{tr}(\Sigma)}{n}} \right] \leq \exp \left(-\frac{n\delta^2}{2} \right). \quad (6.8)$$

さらに $n \geq d$ なら, 最小特異値 $\sigma_{\min}(X)$ は以下の lower deviation inequality を満たす:

$$\mathbb{P} \left[\frac{\sigma_{\min}(X)}{\sqrt{n}} \leq \gamma_{\min} \left(\sqrt{\Sigma} \right) (1 - \delta) - \sqrt{\frac{\text{tr}(\Sigma)}{n}} \right] \leq \exp \left(-\frac{n\delta^2}{2} \right). \quad (6.9)$$

Example 6.2 (Operator norm bounds for the standard Gaussian ensemble)

- $W \in \mathbb{R}^{n \times d}$ は各成分が $\mathcal{N}(0, 1)$ i.i.d. で引かれる random matrix とする ($\Sigma = I_d$) .
- Thm 6.1 より, $n \geq d$ なら, 確率 $1 - 2 \exp\left(-\frac{n\delta^2}{2}\right)$ 以上で

$$\frac{\sigma_{\max}(W)}{\sqrt{n}} \leq 1 + \delta + \sqrt{\frac{d}{n}} \quad \text{and} \quad \frac{\sigma_{\min}(W)}{\sqrt{n}} \geq 1 - \delta - \sqrt{\frac{d}{n}} \quad (6.10)$$

となる.

- よって, 同じ確率で

$$\left\| \left\| \frac{1}{n} W^T W - I_d \right\|_2 \right\| \leq 2\epsilon + \epsilon^2, \quad \text{where } \epsilon = \sqrt{\frac{d}{n}} + \delta. \quad (6.11)$$

- したがって, $d/n \rightarrow 0$ なら, sample covariance $\hat{\Sigma} = \frac{1}{n} W^T W$ は identity matrix I_d の一致推定量となる. ♣

Example 6.3 (Gaussian covariance estimation)

- $X \in \mathbb{R}^{n \times d}$ は Σ -Gaussian ensemble からの random matrix とする.
- このとき $X = W\sqrt{\Sigma}$ と書ける ($W \in \mathbb{R}^{n \times d}$ は standard Gaussian random matrix) ので,

$$\left\| \left\| \frac{1}{n} X^T X - \Sigma \right\| \right\|_2 = \left\| \left\| \sqrt{\Sigma} \left(\frac{1}{n} W^T W - I_d \right) \right\| \right\|_2 \leq \|\Sigma\|_2 \left\| \left\| \frac{1}{n} W^T W - I_d \right\| \right\|_2.$$

- したがって (6.11) より, 任意の $\delta > 0$ に対して確率 $1 - 2 \exp\left(-\frac{n\delta^2}{2}\right)$ で

$$\frac{\|\hat{\Sigma} - \Sigma\|_2}{\|\Sigma\|_2} \leq 2\sqrt{\frac{d}{n}} + 2\delta + \left(\sqrt{\frac{d}{n}} + \delta\right)^2. \quad (6.12)$$

- よって, $\|\hat{\Sigma} - \Sigma\|_2 / \|\Sigma\|_2$ は $d/n \rightarrow 0$ である限り 0 に収束する.



Example 6.4 (Faster rates under trace constraints)

- $\{\gamma_j(\Sigma)\}_{j=1}^d$ は Σ の固有値列で, $\gamma_1(\Sigma)$ がそのうち最大のもの.
- Σ は, 次元に対して独立な定数 C に対し, 次の “trace constraint” を満たすとする:

$$\frac{\text{tr}(\Sigma)}{\|\Sigma\|_2} = \frac{\sum_{j=1}^d \gamma_j(\Sigma)}{\gamma_1(\Sigma)} \leq C. \quad (6.13)$$

- C は Σ の (実質的な) rank と見なせる (\because (6.13) は $C = \text{rank}(\Sigma)$ では常に成立.)
- パラメータ $q \in [0, 1]$ と半径 $R_q > 0$ の the Schatten q -“balls” を, 以下で定義する:

$$\mathbb{B}_q(R_q) := \left\{ \Sigma \in S^{d \times d} \left| \sum_{j=1}^d |\gamma_j(\Sigma)|^q \leq R_q \right. \right\}. \quad (6.14)$$

- $q = 0$ なら, rank R_q 以下の対称行列の集合.
- $q = 1$ なら, trace constraint になる.
- 任意の非零行列 $\Sigma \in \mathbb{B}_q(R_q)$ は, (6.13) を $C = R_q/(\gamma_1(\Sigma))^q$ で満たす.

- ・ (6.13) を満たす任意の Σ に対し, Thm 6.1 は高確率で X の最大特異値が次のように抑えられることを保証する:

$$\frac{\sigma_{\max}(X)}{\sqrt{n}} \leq \gamma_{\max}(\sqrt{\Sigma}) \left(1 + \delta + \sqrt{\frac{C}{n}} \right). \quad (6.15)$$

- ・ $\Sigma = I_d$ のときの bound (6.10) と比べると, C が d に置き換わって “実行的な rank” となっている.



Proof of Theorem 6.1.

- Notation: $\bar{\sigma}_{\max} = \gamma_{\max}(\sqrt{\Sigma})$, $\bar{\sigma}_{\min} = \gamma_{\min}(\sqrt{\Sigma})$.
- 最大/最小特異値の upper/lower bound とともに以下の 2 段階で示す:
 1. 高確率で特異値が期待値に近いことを concentration inequality から示す (Ch.2)
 2. その期待値の bound の導出に Gaussian comparison inequality を用いる (Ch.5)
- ここでは最大特異値の upper bound のみを示す. (最小特異値の lower bound は大体似た方針で示せるがよりテクニカルなので Appendix (Section 6.6) にまわす.)

- $X = W\sqrt{\Sigma}$ と書ける, ただし $W \in \mathbb{R}^{n \times d}$ は i.i.d. $\mathcal{N}(0, 1)$ entries をもつ.
- $W \mapsto \frac{\sigma_{\max}(W\sqrt{\Sigma})}{\sqrt{n}}$ を \mathbb{R}^{nd} 上の実数値写像とみると, これは $L = \bar{\sigma}_{\max}/\sqrt{n}$ で Lipschitz w.r.t. Euclidean norm. (cf. Example 2.32)
- Gaussian r.v. に対する Lipschitz 関数の concentration inequality (Thm 2.26) より,

$$\mathbb{P} [\sigma_{\max}(X) \geq \mathbb{E}[\sigma_{\max}(X)] + \sqrt{n}\bar{\sigma}_{\max}\delta] \leq \exp\left(-\frac{n\delta^2}{2}\right).$$

- したがって, あとは以下を示せば良い:

$$\mathbb{E}[\sigma_{\max}(X)] \leq \sqrt{n}\bar{\sigma}_{\max} + \sqrt{\text{tr}(\Sigma)}. \quad (6.16)$$

- $\sigma_{\max}(X) = \max_{v' \in \mathbb{S}^{d-1}} \|Xv'\|_2$ で, $X = W\sqrt{\Sigma}$, $v = \sqrt{\Sigma}v'$ とすると次のように書ける:

$$\sigma_{\max}(X) = \max_{v \in \mathbb{S}^{d-1}(\Sigma^{-1})} \|Wv\|_2 = \max_{u \in \mathbb{S}^{d-1}} \max_{v \in \mathbb{S}^{d-1}(\Sigma^{-1})} \underbrace{u^T W v}_{Z_{u,v}},$$

ただし $\mathbb{S}^{d-1}(\Sigma^{-1}) := \{v \in \mathbb{R}^d \mid \|\Sigma^{-\frac{1}{2}}v\|_2 = 1\}$.

- $\{Z_{u,v}, (u,v) \in \mathbb{T}\}$ where $\mathbb{T} := \mathbb{S}^{d-1} \times \mathbb{S}^{d-1}(\Sigma^{-1})$ は zero-mean Gaussian process とみなせる.
- 別の Gaussian process $\{Y_{u,v}, (u,v) \in \mathbb{T}\}$ で $\mathbb{E}[(Z_{u,v} - Z_{\tilde{u}\tilde{v}})^2] \leq \mathbb{E}[(Y_{u,v} - Y_{\tilde{u}\tilde{v}})^2]$ for all $(u,v), (\tilde{u}, \tilde{v}) \in \mathbb{T}$ となるようなものを construct することを考える.
- すると Sudakov-Fernique comparison (Thm. 5.27) から以下が言える:

$$\mathbb{E}[\sigma_{\max}(X)] = \mathbb{E} \left[\max_{(u,v) \in \mathbb{T}} Z_{u,v} \right] \leq \mathbb{E} \left[\max_{(u,v) \in \mathbb{T}} Y_{u,v} \right]. \quad (6.17)$$

- $(u, v), (\tilde{u}, \tilde{v}) \in \mathbb{T}$ を given とし, $\|v\|_2 \leq \|\tilde{v}\|_2$ とする.
- まず $Z_{u,v} = u^T W v = \langle \langle W, uv^T \rangle \rangle$ となる, where $\langle \langle A, B \rangle \rangle := \sum_{j=1}^n \sum_{k=1}^d A_{jk} B_{jk}$.
- W は i.i.d. $\mathcal{N}(0, 1)$ entries をもつので,

$$\mathbb{E} [(Z_{u,v} - Z_{\tilde{u}\tilde{v}})^2] = \mathbb{E} [\langle \langle W, uv^T - \tilde{u}\tilde{v}^T \rangle \rangle^2] = \|uv^T - \tilde{u}\tilde{v}^T\|_F^2.$$

- Frobenius norm を変形すると,

$$\begin{aligned} & \|uv^T - \tilde{u}\tilde{v}^T\|_F^2 \\ &= \|u(v - \tilde{v})^T - (u - \tilde{u})\tilde{v}^T\|_F^2 \\ &= \| (u - \tilde{u})\tilde{v}^T \|_F^2 + \|u(v - \tilde{v}) - \mathbf{T}\|_F^2 + 2\langle \langle u(v - \tilde{v})^T, (u - \tilde{u})\tilde{v}^T \rangle \rangle \\ &\leq \|\tilde{v}\|_2^2 \|u - \tilde{u}\|_2^2 + \|u\|_2^2 \|v - \tilde{v}\|_2^2 + 2(\|u\|_2^2 - \langle u, \tilde{u} \rangle)(\langle v, \tilde{v} \rangle - \|\tilde{v}\|_2^2). \end{aligned}$$

- ここで, $\|u\|_2 = \|\tilde{u}\|_2 = 1$ より $\|u\|_2^2 - \langle u, \tilde{u} \rangle \geq 0$.
- 一方, Cauchy-Schwarz と仮定 $\|v\|_2 \leq \|\tilde{v}\|_2$ より, $|\langle v, \tilde{v} \rangle| \leq \|v\|_2 \|\tilde{v}\|_2 \leq \|\tilde{v}\|_2^2$.
- したがって,

$$\|uv^T - \tilde{u}\tilde{v}^T\|_F^2 \leq \|\tilde{v}\|_2^2 \|u - \tilde{u}\|_2^2 + \|v - \tilde{v}\|_2^2.$$

- $\mathbb{S}^{d-1}(\Sigma^{-1})$ の定義より, $\|\tilde{v}\|_2 \leq \bar{\sigma} = \gamma_{\max}(\sqrt{\Sigma})$ なので,

$$\mathbb{E}[(Z_{u,v} - Z_{\tilde{u},\tilde{v}})^2] \leq \bar{\sigma}_{\max}^2 \|u - \tilde{u}\|_2^2 + \|v - \tilde{v}\|_2^2.$$

- Gaussian process $Y_{u,v} := \bar{\sigma}_{\max} \langle g, u \rangle + \langle h, v \rangle$ を定義する (ただし $g \in \mathbb{R}^n, h \in \mathbb{R}^d$ は standard Gaussian rv's) と,

$$\mathbb{E}[(Y_{u,v} - Y_{\tilde{u},\tilde{v}})^2] = \bar{\sigma}_{\max}^2 \|u - \tilde{u}\|_2^2 + \|v - \tilde{v}\|_2^2.$$

- よって Sudakov-Fernique bound (6.17) より,

$$\begin{aligned} \mathbb{E}[\sigma_{\max}(X)] &\leq \mathbb{E} \left[\sup_{(u,v) \in \mathbb{T}} Y_{u,v} \right] = \bar{\sigma}_{\max} \mathbb{E} \left[\sup_{u \in \mathbb{S}^{d-1}} \langle g, u \rangle \right] + \mathbb{E} \left[\sup_{v \in \mathbb{S}^{d-1}(\Sigma^{-1})} \langle h, v \rangle \right] \\ &= \bar{\sigma}_{\max} \mathbb{E}[\|g\|_2] + \mathbb{E}[\|\sqrt{\Sigma}h\|_2]. \end{aligned}$$

- Jensen's inequality から, $\mathbb{E}[\|g\|_2] \leq \sqrt{n}$ ans

$$\mathbb{E}[\|\sqrt{\Sigma}h\|_2] \leq \sqrt{\mathbb{E}[h^T \Sigma h]} = \sqrt{\text{tr}(\Sigma)} \text{ となり, (6.16) が示された.}$$

□

6.3 Covariance matrices from sub-Gaussian ensembles

•